PROYECTO 3 · DEEP LEARNING 2026

Text-to-SQL con LoRA

Fine-tuning de Qwen2.5-Coder-1.5B para generar MySQL 8.4.10

```
esquema (SHOW CREATE TABLE)  +  pregunta en espanol
-->  SELECT ... una sola consulta, determinista
```

Cindy Gualim · Gadiel Ocana
Universidad del Valle

EL PROBLEMA

Una pregunta en espanol, una consulta correcta

El evaluador entrega el esquema tal como lo devuelve SHOW CREATE TABLE, con sus COMMENT, y una pregunta que indica que columnas devolver.

```
"Cuantas reservas tiene cada tipo
 de habitacion? Devuelve el
 nombre del tipo y la cantidad."
```

→

```
SELECT rt.name, COUNT(*)
FROM bookings b
JOIN rooms r ON b.room_id = r.id
JOIN room_types rt ON r.type_id = rt.id
GROUP BY rt.id, rt.name
```

> Se mide por exactitud por ejecucion: se comparan los resultados de ejecutar las dos consultas, nunca su texto. Y sobre bases y preguntas que no conocemos.

RESTRICCIONES

Cada condicion del enunciado es una decision en el codigo

ONLY_FULL_GROUP_BY activo	Las 32 plantillas agrupan por la clave primaria ademas de la etiqueta. Es el error que mas consultas mata en MySQL 8.4 por defecto.
Una consulta que modifique la base: -10	extraer_sql() corta en el primer punto y coma y rechaza todo lo que empiece por INSERT, UPDATE, DELETE o DDL. Se pierde la pregunta, no los puntos.
Generacion determinista	do_sample=False, num_beams=1 y temperature/top_p/top_k anulados para que no queden los valores por defecto del modelo.
Particion por esquema, no por pregunta	Las bases veterinaria y hotel no comparten ni un nombre de tabla con las 12 de entrenamiento.
30 s por pregunta, 5 min de carga	Carga perezosa con candado, una sola vez; la autocorreccion tiene tope duro de 3 llamadas, contado fuera del modelo.

DATOS

Como se construyo el dataset

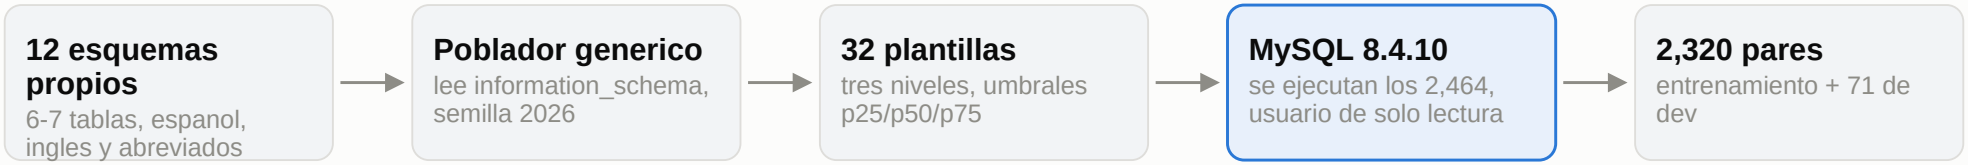

- Los umbrales de los filtros salen de muestrear los datos reales, no son constantes inventadas: un filtro que no coincide con ningun dato produce un par que no ensena nada.
- El poblador es generico a proposito. Sirve igual para los esquemas de validacion, y evita que los datos de las dos particiones se parezcan por haberlos escrito con la misma mano.

DATASET

2,464 pares, todos ejecutados en el motor

2,464
GENERADOS
32 plantillas x 12 bases

97.0%
VALIDOS
2,391 pares

73
DESCARTADOS
todos por resultado vacio

0
ERRORES DE SINTAXIS
y 0 de ONLY_FULL_GROUP_BY

PARES DE ENTRENAMIENTO POR NIVEL

Por que se descarta un resultado vacio: con cero filas la comparacion por ejecucion no distingue una consulta correcta de una rota. Cualquier error que tambien devuelva vacio acierta.

HALLAZGO

Buscabamos preguntas repetidas y encontramos ambiguedad

DOS CLAVES FORANEAS A LA MISMA TABLA

```
vuelos.origen  --> aeropuertos.iata
vuelos.destino --> aeropuertos.iata
```

"Cuantos vuelos tiene cada aeropuerto?" no determina por cual de las dos se une. Lo mismo pasa con prestamos, que apunta a clientes y a sucursales: ambas tienen una columna nombre.

PREGUNTAS AMBIGUAS, TRAS CADA CORRECCION

- Lo grave no era el par descartado sino el que se quedaba: entrenaba al modelo a adivinar.

VALIDACION

Dos esquemas que el modelo nunca vio

ENTRENAMIENTO · 12 esquemas

biblioteca, ecommerce, clinica, universidad, hr, restaurante, aerolinea, gym, inmobiliaria, logistica, streaming, banco

n = 0

sin interseccion

VALIDACION · 2 esquemas

veterinaria (espanol) y hotel (ingles). 14 tablas que no aparecen en ninguna base de entrenamiento.

40
PREGUNTAS
escritas a mano, no generadas

13/13/14
POR NIVEL
facil / media / dificil

81
PESO TOTAL
pesos 1, 2 y 3

5
CON ORDEN EXIGIDO
el resto compara como conjunto

Escribirlas a mano encontro dos defectos del poblador que ninguna prueba automatica habria encontrado: perros con fecha de nacimiento de persona, y score de resena llegando a 100 cuando su COMMENT dice 1 a 5.

ENTRENAMIENTO

Dos configuraciones, un solo factor distinto

CONFIGURACION A

r = 8

~9M parametros entrenables

CONFIGURACION B

r = 32

~36M parametros entrenables

FIJO EN AMBAS

```
alpha=32   dropout=0.05   lr=2e-4   2 epocas   lote efectivo 16
modulos: q_proj k_proj v_proj o_proj gate_proj up_proj down_proj
```

alpha se mantiene en 32 a proposito. Escalarlo con el rank cambiaria a la vez la capacidad del adapter y la magnitud de su contribucion, y la diferencia no se podria atribuir a ninguno de los dos.

BASELINE MEDIDO

El modelo sin adapter ya parte de 0.580

PESO ACERTADO SOBRE EL DISPONIBLE (12/13 · 20/26 · 15/42)

Acierta casi todo lo facil y se derrumba en lo dificil, que pesa 3. Ahi esta el margen, y tambien la dificultad: el umbral de +0.15 de mejora se mide contra una base alta.

PREGUNTA 38 · GENERADO ● tabla inexistente

```
SELECT T1.country, SUM(T2.total_amount)...
FROM bookings AS T1
JOIN payments AS T2 ON T1.id = T2.booking_id
GROUP BY T1.country
```

La base hotel no tiene ninguna tabla payments: el modelo la invento a partir de lo que sabe de otros esquemas, en vez de leer el que tiene delante. No es un error de razonamiento sino de anclaje, y es justo lo que 2,320 ejemplos pueden corregir.

Tres variantes sobre el mismo adapter

Directa
el prompt del contrato, una sola generacion

→

Few-shot
tres ejemplos resueltos sobre un esquema inventado

→

Autocorreccion
ejecuta la consulta y la reescribe con el error

EL CICLO DE AUTOCORRECCION

```
generar  -->  ejecutar(sql)  -->  error del motor  -->  regenerar
tope de 3 llamadas, contado fuera del modelo
```

- **Su limite duro**
  Solo puede arreglar lo que el motor reporta: Unknown column, Table doesn't exist. No hace nada por un resultado distinto, donde la consulta corre sin error y nada le indica al modelo que esta equivocada.

ERRORES

Donde se pierde el peso, medido en el baseline

PESO PERDIDO POR CATEGORIA · 34 DE 81

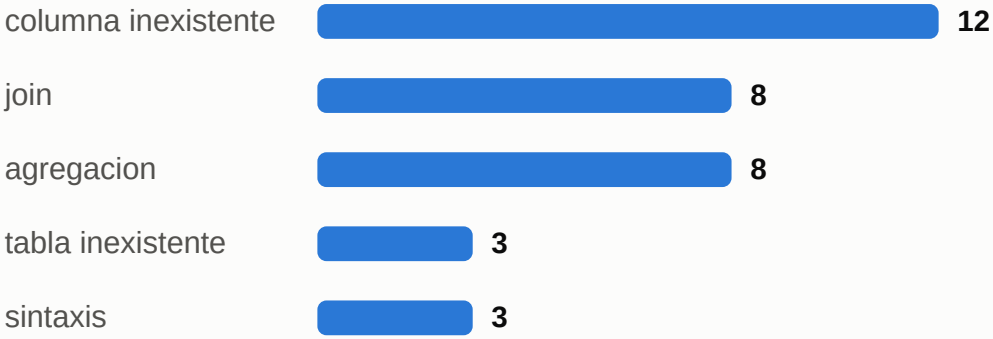

15 DE LOS 34 PUNTOS SON ANCLAJE AL ESQUEMA

Columna y tabla inexistente suman 15 del peso perdido: el 44%. Son los unicos errores que el motor reporta de forma explicita, asi que son los que el fine-tuning y la autocorreccion pueden atacar. Los de agregacion y join exigen entender la pregunta.

13 preguntas falladas de 40, pero no cuestan lo mismo: fallar una dificil equivale a fallar tres faciles.

LO QUE EL MOTOR REPORTA · sintaxis · tabla inexistente · columna inexistente

LO QUE HAY QUE INFERIR · join · agregacion · filtro · resultado distinto

PREDICCION

Que esperamos en la evaluacion oculta

EX PONDERADA ESPERADA

0.55

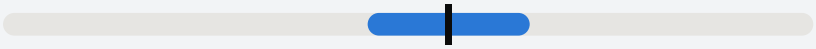

MEJORA SOBRE EL MODELO SIN ADAPTER

+0.08 a +0.19

- en riesgo: el umbral del enunciado es +0.15
- El baseline medido es alto, 0.580. La mejora se mide contra esa base, asi que el margen es estrecho por arriba.
- El techo optimista: si el adapter arreglara todo el anclaje al esquema, la EX subiria a 0.765 y la mejora seria +0.185.
- Descontamos 0.15 sobre la evaluacion oculta: nuestra validacion la escribimos nosotros, sobre esquemas que diseniamos nosotros.